Eduarda Floripo

Gabriel Botega

Helena Pacheco

Luiza Monteiro

Maria Eduarda Ourique

Relatório de Limpeza de Dados: Fase 2

Análise de Dados de Enchentes do INCT SiMAI · Coleta, Preparação e Análise de Dados

Profª Katherine Bianchini Esper de Vargas

Porto Alegre, 10 de novembro de 2026

1. Objetivo

Este relatório descreve como verificamos e limpamos o data.json do INCT SiMAI, base da Tela 1, e a base externa da Tela 2, que é a mancha de inundação de maio de 2024 da UFRGS. Para cada inconsistência informamos onde ela aparece, por que é um problema, qual tratamento o nosso notebook aplica e por quê. Também registramos as limitações que ainda existem depois da limpeza.

Arquivo	**Função**
dados/originais/data.json	Arquivo original do INCT, sem alterações
notebooks/limpeza.ipynb [AJUSTAR NOME]	Notebook de limpeza da equipe
dados/processados/data_alterado.json	Saída do notebook, com os dados corrigidos

2. Exploração inicial do data.json

O arquivo tem 71 níveis do Guaíba, de 3,0 m a 10,0 m em passos de 0,1 m. Cada nível tem os mesmos 94 bairros, e cada bairro tem 5 campos inteiros. Em formato longo são 6.674 linhas e 7 colunas.

Na exploração, conferimos os pontos abaixo e não encontramos problema:

- nenhum nível falta e nenhum bairro falta ou aparece duplicado;
- total_buildings e population são iguais em todos os níveis de um mesmo bairro;
- não há valores negativos, e affected_buildings nunca passa de total_buildings;
- a população total soma 1.332.845 habitantes, o mesmo valor do Censo IBGE 2022 para Porto Alegre.

3. Inconsistências encontradas

Seguimos a dica do enunciado. Quando o rio sobe, a área alagada só aumenta, então o número de prédios afetados de um bairro não pode diminuir de um nível para o seguinte. No arquivo original encontramos 12 quedas, em 5 bairros.

Também verificamos se percentage e affected_population estão coerentes com os outros campos.

#	Inconsistência	Onde aparece	Valores no original
I1	Zero isolado no meio da série	Lageado 8,1 m; Rubem Berta 8,8 m; Centro Histórico 9,7 e 9,8 m	Lageado 108 → **0** → 110; Rubem Berta 252 → **0** → 285; Centro Histórico 2.050 → **0** → **0** → 2.130
I2	Pico isolado	Espírito Santo 4,7 m	46 → **2.101** → 47
I3	Valores iniciais altos demais	Espírito Santo 3,0 a 3,4 m	637, 637, 637, 637, 633 e depois 25 em 3,5 m. Nenhum nível acima volta a 637 (o máximo é 133, em 10 m)
I4	Oscilação pequena	Arquipélago	Alterna entre 4.674 e 4.688 prédios (o total do bairro é 4.688)
I5	Porcentagem arredondada para cima	Todos os níveis e bairros	percentage é o teto de 100 × afetados / total em 6.672 de 6.674 linhas. Um prédio em 4.696 (0,02 %) aparece como 1 %
I6	Exceção à regra do arredondamento	Boa Vista do Sul 7,2 e 7,3 m	686 / 2.450 = 28,00 % exato, mas o arquivo diz 29 %
I7	População afetada calculada com a porcentagem arredondada	Todos	affected_population = population × percentage / 100, com a porcentagem já arredondada para cima
I8	Ordem dos bairros diferente	Nível 5,3 m	A partir da 56ª posição os bairros aparecem em outra ordem

Por que são problemas.

- **I1:** um zero entre dois valores altos não tem sentido físico. O mais provável é um dado ausente que foi gravado como 0. Além disso, o total da cidade cai cerca de 12 mil pessoas em 9,7 m.
- **I2 e I3:** um nível mais baixo do rio não pode alagar mais prédios do que os níveis mais altos.
- **I4:** a variação é pequena (menos de 0,3 % do bairro), mas também desrespeita a regra de que os prédios afetados não diminuem.
- **I5 a I7:** o arredondamento para cima superestima a população afetada. Somando a cidade, o excesso fica entre 1,3 mil e 4 mil pessoas, conforme o nível.

- **I8:** um código que dependa da ordem do arquivo pode comparar bairros errados.

4. Tratamento aplicado no notebook

O notebook percorre os níveis em sequência e guarda, para cada bairro, o último valor de prédios afetados e de população afetada. As regras são:

1. **Prédios e população afetados não podem cair.** Se o valor de um nível é menor que o do nível anterior, o notebook repete o valor anterior. Com isso, cada bairro fica com o maior valor visto até aquele nível (máximo acumulado).
2. **A porcentagem é recalculada.** O notebook calcula `percentage = round(affected_buildings / total_buildings × 100)` a partir dos prédios já corrigidos.
3. **A saída mantém a estrutura do original.** O resultado é salvo em `data_alterado.json`, que continua aninhado como o JSON do INCT.

```
if construcoes_afetadas < c_anterior:
    construcoes_afetadas = c_anterior
if populacao_afetada < p_anterior:
    populacao_afetada = p_anterior


porcentagem = (construcoes_afetadas / total_construcoes) * 100
dados['percentage'] = round(porcentagem)
```

Justificativa. Escolhemos repetir o valor anterior porque é uma regra simples, fácil de explicar e que garante a coerência física: o número de prédios afetados não diminui quando o rio sobe. Para os zeros isolados (I1), repetir o valor anterior equivale a considerar que nenhum prédio novo foi alagado naquele nível. É uma estimativa conservadora, já que o valor do nível seguinte é apenas um pouco maior. Na oscilação de Arquipélago (I4), a mudança é de poucos prédios e não altera a leitura do dashboard. Recalcular a porcentagem com `round()` corrige o

arredondamento sempre para cima (I5 e I6). O notebook acessa os dados pelo nome do bairro, então a ordem diferente no nível 5,3 m (I8) não causa erro.

4.1 Resultado verificado

Comparamos data_alterado.json com o original linha a linha:

Campo	**Valores alterados**	**Bairros**
affected_buildings	135	5 (Espírito Santo 66, Arquipélago 65, Centro Histórico 2, Lageado 1, Rubem Berta 1)
affected_population	70	4 (Espírito Santo, Centro Histórico, Lageado, Rubem Berta)
percentage	1.333	52
total_buildings, population	0	—

Depois do tratamento, nenhuma série de bairro diminui. A curva da cidade também só cresce: a queda falsa em 9,7 m desapareceu. Os zeros isolados passaram a ter o valor do nível anterior: 108 em Lageado, 252 em Rubem Berta e 2.050 em Centro Histórico.

Nível	**Pop. afetada (original)**	**Pop. afetada (alterado)**
3,0 m	34.605	34.605
5,3 m	138.414	141.435
9,7 m	252.080	269.676
10,0 m	274.993	277.915

5. Limitações conhecidas e ajustes previstos

A revisão do resultado mostrou três situações em que a regra “repetir o valor anterior” não basta. Elas ficam registradas aqui e serão corrigidas no notebook antes do dashboard (Fase 3).

L1 — O pico de Espírito Santo se espalha. O valor 2.101 de 4,7 m (I2) é maior que o anterior, então a regra o aceita. Daí em diante ele é repetido em todos os níveis até 10 m. No data_alterado.json, Espírito Santo aparece com 2.101 prédios (63 %) e 3.121 pessoas afetadas de 4,7 m a 10 m, quando os vizinhos indicam entre 46 e 133 prédios (1 % a 4 %). Em 5,3 m isso representa cerca de 3 mil pessoas a mais. *Ajuste previsto:* tratar 2.101 como valor inválido, interpolar entre 46 e 47 e só depois aplicar a regra.

L2 — Os valores iniciais de Espírito Santo foram mantidos e propagados. Os 637 prédios de 3,0 a 3,4 m (I3) passam a valer também de 3,5 m em diante, até chegar o pico. *Ajuste previsto:* substituir esses valores pelo primeiro valor válido (25 prédios em 3,5 m).

L3 — Porcentagem e população ficaram incoerentes entre si. O notebook recalcula a porcentagem, mas mantém a população afetada do original, que foi calculada com a porcentagem arredondada para cima. No arquivo alterado, 1.277 linhas não seguem mais a fórmula population × percentage / 100. Em 187 delas, de 25 bairros, a porcentagem é 0 % e a população afetada é maior que zero. Um exemplo é Chapéu do Sol em 5,3 m: 4 prédios, 0 % e 56 pessoas afetadas, quando pela fração exata seriam cerca de 12. *Ajuste previsto:* recalcular affected_population = population × affected_buildings / total_buildings e guardar a porcentagem com casas decimais, em vez de arredondá-la para inteiro.

Outros pontos.

- O notebook supõe que os níveis estão em ordem no arquivo. Eles estão, mas o código vai ordenar os níveis pelo valor numérico antes de percorrê-los.
- A saída ainda está no formato aninhado. Ela será convertida para o formato longo pedido no enunciado, com uma linha por nível e bairro.
- As alterações vão ser salvas em um log (bairro, nível, valor antes e depois), para a devolutiva ao INCT.

- Uma limitação continua no dado e será avisada no dashboard: a população afetada é uma **estimativa**. Ela supõe que os moradores se distribuem igualmente entre todos os prédios do bairro, inclusive os não residenciais.

6. Base externa: mancha de inundação de maio de 2024 (UFRGS)

6.1 Origem e coleta

A base externa utilizada no projeto foi disponibilizada pela Universidade Federal do Rio Grande do Sul (UFRGS) por meio do repositório Zenodo, no conjunto de dados referente às enchentes de maio de 2024 na Região Hidrográfica do Guaíba (https://zenodo.org/records/13227745). O arquivo original utilizado foi cheias_rhguaiba_2024_db_v12.gpkg, no formato GeoPackage (GPKG), que reúne camadas geográficas vetoriais e seus respectivos atributos.

A coleta foi realizada por meio do download do arquivo GeoPackage. Em seguida, os dados foram carregados e analisados em Python, no ambiente Jupyter Notebook, com as bibliotecas GeoPandas, Pandas e Pyogrio. [COMPLETAR: data de coleta e script de download, ex.: urllib.request.urlretrieve ou requests.get apontando para o link do arquivo no Zenodo.

Foram selecionadas quatro camadas relevantes: rhguaiba_sentinel2_agua_obs_06052024_validada (água observada e validada em 06/05/2024); rhguaiba-sinosgravatai_sentinel2_agua_obs_08052024_validada (água observada e validada em 08/05/2024); poa_inundacao_2024_530cm (mancha de inundação associada ao nível de 5,3 metros em Porto Alegre); e poa_admin_bairros (limites administrativos dos bairros de Porto Alegre).

As camadas passaram por verificações de valores ausentes, geometrias vazias ou inválidas, duplicidades, sistemas de coordenadas e abrangência territorial. Para a análise espacial, as geometrias foram reprojetadas para o

sistema SIRGAS 2000 / UTM zona 22S (EPSG:31982), o que permitiu o cálculo de áreas em quilômetros quadrados.

Posteriormente, foram realizados recortes espaciais e interseções com os limites dos bairros de Porto Alegre. Os resultados foram utilizados na produção de tabelas, gráficos e mapas, além da integração com os indicadores de edificações e população afetadas do INCT SiMAI para o cenário de 5,3 metros.

A coleta foi realizada por meio do download do arquivo GeoPackage em 8 de novembro de 2026. Em seguida, os dados foram carregados e analisados em Python, no ambiente Jupyter Notebook, com as bibliotecas GeoPandas, Pandas e Pyogrio.

Arquivo	**Conteúdo**
ufrgs_poa_limpo.gpkg	34 polígonos da mancha recortados para Porto Alegre (EPSG:4326). Colunas SIGLA_UF, MUN_KM2 e area_km2, sem nome de bairro
ufrgs_cobertura_530cm_por_bairro.csv	83 bairros, com área do bairro, área sob a mancha e % de cobertura
ufrgs_area_por_bairro.csv	32 bairros com area_agua_km2
ufrgs_inct_integrados_530cm.csv	Mancha cruzada com o INCT em 5,3 m (82 bairros)

6.2 Inconsistências encontradas

#	**Inconsistência**	**Onde aparece**	**Tratamento**
E 1	Malhas de bairros diferentes	O INCT tem 94 bairros e a malha da UFRGS tem 83. Os 11 sem par são os bairros criados em 2016: Aberta dos Morros, Boa Vista do Sul, Costa e Silva, Extrema, Jardim Europa, Jardim Leopoldina, Parque Santa Fé, Pitinga, Santa Rosa de Lima, São Caetano e Sétimo Céu	Manter e avisar. No cruzamento, esses bairros ficam sem dado da mancha, sem receber zero
E 2	Grafias diferentes	Vila São José (INCT) e SAO JOSE (UFRGS); Coronel Aparício Borges e CEL APARICIO BORGES; Mont'Serrat e MONTSERRAT; Passo D'Areia e PASSO DAREIA	Correção. Os nomes são cruzados sem acento e sem apóstrofo, com uma tabela de equivalências. No integrado atual, SAO JOSE ficou fora (83 → 82 linhas)

#	Inconsistência	Onde aparece	Tratamento
E 3	Duas medidas de área alagada que não batem	Somando os bairros, area_agua_km2 dá 119,9 km² e area_mancha_km2 dá 137,7 km². Exemplos: Belém Novo 7,4 contra 18,4; Lami 11,3 contra 14,6	[COMPLETAR: explicar a diferença entre as colunas e qual será usada]
E 4	Integrado herda as limitações L1 a L3	Espírito Santo aparece com 63 % de prédios afetados em 5,3 m, contra 10,8 % da área coberta pela mancha. Chapéu do Sol e Lageado aparecem com 0 % de prédios e mais de 50 pessoas afetadas	Gerar o integrado de novo depois dos ajustes da seção 5
E 5	diferenca_pp compara grandezas diferentes	A coluna subtrai a % de prédios afetados (INCT) da % de área coberta pela mancha (UFRGS). Uma é a proporção de prédios do bairro, a outra é a proporção da área	Manter e avisar. A diferença indica onde vale olhar com mais atenção, mas não mede o erro da simulação
E 6	Cálculo de área	As áreas precisam ser calculadas em projeção métrica (SIRGAS 2000 / UTM 22S, EPSG:31982), não em graus	[CONFIRMAR no script de cruzamento]

7. Devolutiva para o INCT

1. Valores 0 isolados em Lageado (8,1 m), Rubem Berta (8,8 m) e Centro Histórico (9,7 e 9,8 m).
2. Espírito Santo: pico de 2.101 prédios em 4,7 m, e valores de 633 a 637 prédios de 3,0 a 3,4 m, maiores que todos os níveis acima.
3. Oscilação de alguns prédios em Arquipélago.
4. percentage arredondada para cima e affected_population calculada a partir dela, o que superestima a população afetada. Inclui o caso de Boa Vista do Sul (7,2 e 7,3 m), em que 28 % exatos aparecem como 29 %.
5. Ordem diferente dos bairros no nível 5,3 m.

8. Uso de ferramentas de IA

O uso de Inteligência Artificial foi para mapear onde estavam os problemas do enunciado para acompanhar como estava o resultado do script gerado. Ela pôde mostrar então que não haviam dados nulos, nem problemáticas de encoding,

por exemplo. Nessa visão, conseguiu demonstrar quais casos estavam apontando o defeito de apontar que menos construções e pessoas seriam afetadas mesmo com um nível mais alto de água. E, também, para a formatação desse relatório.